Linux网络--数据链路层以太网帧与交换机

- Linux网络--数据链路层以太网帧与交换机
- 1. 网络层下面是链路层
  - 1.1 逻辑路径与物理区间
  - 1.2 以太网是一套标准
- 2. 以太网帧格式
  - 2.1 基本结构
  - 2.2 为什么数据区最小是 46 字节
  - 2.3 接收方如何识别真实数据长度
- 3. IP 报文的逐层封装
  - 3.1 目的 IP 与 MAC 的变化
  - 3.2 发送前的完整判断
  - 3.3 路由器收到的帧为什么不是原样通过
- 4. 局域网内怎样交付
  - 4.1 交换机未学习时的泛洪
  - 4.2 已知单播、未知单播和广播
  - 4.3 网卡混杂模式
  - 4.4 交换机地址表的动态变化
  - 4.5 广播域与 VLAN
  - 4.6 环路与生成树
- 5. 碰撞与交换机
  - 5.1 共享以太网
  - 5.2 为什么更长的帧更容易冲突
    - 争用窗口与传播时延
  - 5.3 交换机怎样减少碰撞
- 6. 链路层与上层可靠性
  - 6.1 CRC 能发现什么
  - 6.2 抓包为什么经常看不到 FCS
  - 6.3 以太网不只是一个速率
- 7. 一个以太网帧的具体视角
  - 7.1 交换机不读取 IP 目的地址
- 8. 局域网性能为什么会被主机数量影响
  - 8.1 全双工与半双工
  - 8.2 链路速率与吞吐量
  - 8.3 观测接口与链路
- 9. 从帧到网卡

    - 9.1 帧不是抽象对象
    - 9.2 队列与丢包
    - 9.3 VLAN 帧的额外长度
    - 9.4 交换机角色与路由器角色
    - 9.5 抓包时如何判断问题层级
    - 9.6 广播不是可靠发现协议
    - 9.7 二层故障检查清单
- 10. 还缺一步：下一跳 MAC 从哪里来

Linux网络--数据链路层以太网帧与交换机

> ⓘ **系列导航**
>
> 上一篇：Linux网络--网络层路由表、逐跳转发与ICMP诊断
> 本篇：以太网帧与交换机
> 下一篇：Linux网络--数据链路层ARP地址解析与缓存

- Linux网络--数据链路层以太网帧与交换机
- 1. 网络层下面是链路层
    - 1.1 逻辑路径与物理区间
    - 1.2 以太网是一套标准
- 2. 以太网帧格式
    - 2.1 基本结构
    - 2.2 为什么数据区最小是 46 字节
    - 2.3 接收方如何识别真实数据长度
- 3. IP 报文的逐层封装
    - 3.1 目的 IP 与 MAC 的变化
    - 3.2 发送前的完整判断
    - 3.3 路由器收到的帧为什么不是原样通过
- 4. 局域网内怎样交付
    - 4.1 交换机未学习时的泛洪
    - 4.2 已知单播、未知单播和广播
    - 4.3 网卡混杂模式
    - 4.4 交换机地址表的动态变化
    - 4.5 广播域与 VLAN
    - 4.6 环路与生成树

- 5. 碰撞与交换机
  - 5.1 共享以太网
  - 5.2 为什么更长的帧更容易冲突
    - 争用窗口与传播时延
  - 5.3 交换机怎样减少碰撞
- 6. 链路层与上层可靠性
  - 6.1 CRC 能发现什么
  - 6.2 抓包为什么经常看不到 FCS
  - 6.3 以太网不只是一个速率
- 7. 一个以太网帧的具体视角
  - 7.1 交换机不读取 IP 目的地址
- 8. 局域网性能为什么会被主机数量影响
  - 8.1 全双工与半双工
  - 8.2 链路速率与吞吐量
  - 8.3 观测接口与链路
- 9. 从帧到网卡
  - 9.1 帧不是抽象对象
  - 9.2 队列与丢包
  - 9.3 VLAN 帧的额外长度
  - 9.4 交换机角色与路由器角色
  - 9.5 抓包时如何判断问题层级
  - 9.6 广播不是可靠发现协议
  - 9.7 二层故障检查清单
- 10. 还缺一步：下一跳 MAC 从哪里来

路由表给出下一跳 IP 后，IP 数据报仍然不能直接“飞到”下一台路由器。它必须交给网卡，封装成当前链路能够传输的数据帧。

跨网络通信看起来是 IP 在端到端寻找路径；拆到每一跳，实际上都是一个个局域网在接力。本篇从真正在线路上传输的以太网帧开始，解释 MAC 地址、帧类型、PAD、碰撞和交换机。

1. 网络层下面是链路层

1.1 逻辑路径与物理区间

从源主机到目的主机，IP 地址描述整体起点和终点；MAC 地址描述每一个局域网区间的发送端和接收端。

```
IP：北京 -> 上海
MAC：当前路口 -> 下一个路口
```

主机 A 发给路由器 A、路由器 A 发给路由器 B、路由器 B 发给最终主机，每一段都可能使用不同的 MAC 地址。

1.2 以太网是一套标准

以太网不是某个唯一网络，而是一套包含链路层和部分物理层内容的技术标准：

- 拓扑和访问方式；
- 帧格式；
- 传输速率；
- 双绞线、光纤等物理介质规范。

同一网络可能混用不同物理速率，但只要链路协议允许，IP 上层不需要关心底层是双绞线、光纤还是无线链路。

2. 以太网帧格式

2.1 基本结构

标准以太网帧：

字段	长度	作用
目的 MAC	6 字节	当前链路上的接收接口
源 MAC	6 字节	当前链路上的发送接口
类型	2 字节	有效载荷属于哪个上层协议
数据	46 至 1500 字节	通常是 IP 数据报或 ARP 报文
FCS	4 字节	帧校验序列，使用 CRC

常见类型：

EtherType	有效载荷
`0x0800`	IPv4
`0x0806`	ARP
`0x8035`	RARP

MAC 地址长度为 48 位，通常写成六组十六进制：

```
00:1A:2B:3C:4D:5E
```

MAC 地址只在当前广播域内有意义；IP 地址用于跨网络定位。

2.2 为什么数据区最小是 46 字节

早期共享以太网必须保证冲突检测正常工作，因此定义了最小帧长。去掉 14 字节帧头和 4 字节 FCS 后，最小有效载荷为 46 字节。

如果 IP 或 ARP 载荷更短，链路层会添加 PAD：

```
帧头 14 + 有效载荷 46 + FCS 4 = 最小完整帧 64 字节
```

最大标准有效载荷为 1500 字节：

```
帧头 14 + 1500 + FCS 4 = 最大完整帧 1518 字节
```

VLAN 标签会增加额外字段，因此实际最大帧长可能更大。

2.3 接收方如何识别真实数据长度

接收方可以先按固定位置分离帧头和 FCS，但数据区可能包含 PAD。真正的 IP 数据报长度要看 IP 首部的 16 位总长度字段。

```
以太网数据区包含：IP 数据报 + PAD
IP 总长度告诉接收方：真正的 IP 数据报到哪里结束
```

因此 PAD 不会污染 IP 有效载荷。

3. IP 报文的逐层封装

应用数据从上层向下传递时，每层添加自己的控制信息：

```
应用数据
    + TCP/UDP 首部
        + IP 首部
            + 以太网首部
                -> 网卡发送
```

接收方向相反：

```
网卡接收
    -> 链路层检查 MAC 和 FCS
        -> 网络层检查 IP 和协议号
            -> 传输层按端口交给进程
```

路由器不会保留旧的链路层帧直接跨网发送。它会拆到网络层，查询新的下一跳，再生成新的链路层封装。

3.1 目的 IP 与 MAC 的变化

项目	跨路由时是否变化
目的 IP	普通路由中保持不变
源 IP	普通路由中保持不变；NAT 场景除外
TTL	每经过一个路由器通常减 1
目的 MAC	每跳按下一跳重新填写
源 MAC	每跳按当前发送接口重写

这就是“IP 端到端，MAC 一跳一跳”的含义。

3.2 发送前的完整判断

主机发送一个 IP 数据报前，通常依次完成：

1. 用目的 IP 与本地路由条目比较；
2. 判断目标是否在本子网；
3. 若在本子网，下一跳就是目标主机；
4. 若不在本子网，下一跳是默认网关；
5. 查 ARP/邻居缓存得到下一跳 MAC；
6. 检查数据报是否超过接口 MTU；
7. 封装以太网帧并交给网卡。

因此，一个报文能否发出不仅取决于“有没有目的 IP”，还取决于路由、邻居解析和链路 MTU。

3.3 路由器收到的帧为什么不是原样通过

帧头中的源 MAC、目的 MAC 和 FCS 都只针对当前链路。路由器把帧送到新的链路时，旧 MAC 已经失去意义。

原帧：

```
src MAC A -> dst MAC R1
```

路由器 R1 重新封装后：

```
src MAC R1 -> dst MAC R2
```

IP 目的地址保持 `5.1.0.100`，但当前链路的接收者已经变成 R2。这就是“目的 IP 决定最终去哪里，目的 MAC 决定这一帧先交给谁”。

4. 局域网内怎样交付

4.1 交换机未学习时的泛洪

交换机启动时 MAC 地址表为空。收到主机 A 发给主机 E 的帧后：

1. 记录源 MAC A 来自左侧接口；
2. 查找目的 MAC E；
3. 表里没有 E，于是向其他端口泛洪；

4. E 返回应答时，交换机记录 E 所在接口；
5. 后续 A 与 E 的帧只走相应端口。

交换机学习的是：

```
源 MAC -> 入接口
```

转发时依据：

```
目的 MAC -> 出接口
```

4.2 已知单播、未知单播和广播

帧类型	交换机典型行为
已知单播	只从目的 MAC 对应端口发送
未知单播	在 VLAN 内除入接口外泛洪
广播	在 VLAN 内除入接口外泛洪
组播	根据二层组播配置转发或泛洪

交换机默认划分碰撞域，但不划分广播域。一个广播帧仍然可以在交换机连接的所有端口扩散，直到使用 VLAN 进行隔离。

4.3 网卡混杂模式

正常情况下，网卡只把目的 MAC 为本机或广播、组播的帧交给协议栈。混杂模式会接收链路上能够看到的所有帧，Wireshark、tcpdump 等抓包工具会利用这一能力。

启用混杂模式不等于能跨路由器看到所有互联网流量。它最多只能看到所在交换环境允许到达网卡的帧。

4.4 交换机地址表的动态变化

MAC 表项不是永久配置，通常还带有老化时间。若主机长时间不发送帧，交换机可能删除该条目；下次发往该 MAC 时又会暂时泛洪并重新学习。

设备移动也可能导致表项变化：

```
MAC A 原来在端口 1
设备换到端口 8 并发送帧
交换机把 MAC A 更新为端口 8
```

这个特性既有自动适应能力，也可能被伪造源 MAC 的行为利用。

4.5 广播域与 VLAN

一个交换机默认可以转发广播。大量广播帧会占用所有端口和链路带宽。

VLAN 把一台物理交换机逻辑上分成多个广播域：

```
VLAN 10：研发网络
VLAN 20：办公网络
VLAN 30：访客网络
```

同一 VLAN 内可以通过二层交换通信；不同 VLAN 需要三层路由器或三层交换机转发。

因此：

```
交换机端口通常划分碰撞域
VLAN 划分广播域
路由器连接不同三层网络
```

三者不能混为一谈。

4.6 环路与生成树

多个交换机互连时，如果物理拓扑形成环路，广播帧可能不断循环，并被复制到整个二层网络，造成广播风暴和 MAC 表震荡。

生成树协议（STP）和相关协议通过阻塞部分冗余端口，构造无环逻辑拓扑。物理链路仍然保留，主链路故障时再启用备份路径。

交换机环路是“网络突然变慢、广播流量暴增”的常见原因之一。

5. 碰撞与交换机

5.1 共享以太网

在半双工共享总线中，多台主机共用同一介质。如果两台主机同时发送，电信号叠加，数据发生碰撞。

CSMA/CD 的基本过程：

1. 发送前监听信道；
2. 信道空闲时开始发送；
3. 发送时继续检测碰撞；
4. 检测到碰撞后停止发送；
5. 随机退避，稍后重试。

碰撞检测只是对已经发生的冲突做出处理，不代表链路层提供可靠交付。帧是否真正被上层接收、业务是否成功，仍由上层协议和应用判定。

5.2 为什么更长的帧更容易冲突

帧越长，占用共享介质的时间越长，与其他主机发送发生重叠的概率越高。短帧可以更快释放信道，但帧太短又会增加首部开销和发送次数。

以太网 MTU 和最小帧长是在效率、冲突概率和硬件约束之间形成的工程折中。

争用窗口与传播时延

经典 CSMA/CD 不仅要发现本机发送时的碰撞，还要让所有参与主机在发送早期就能获知碰撞。最小帧长与网络最大传播时延相关：如果帧太短，发送方可能在检测到碰撞之前就已经发完，错误帧已经离开。

现代交换式全双工网络通过独立收发通道消除了这种共享总线争用，但无线网络仍需要通过 CSMA/CA、ACK、退避和速率控制处理共享无线介质。

5.3 交换机怎样减少碰撞

交换机的每个端口通常构成独立的碰撞域。全双工链路中，发送和接收使用不同方向，正常通信不再需要传统 CSMA/CD。

交换机只是减少了共享介质碰撞，不消除：

- 上行链路带宽不足；
- 交换机内部拥塞；
- 广播泛洪；
- 链路错误和丢包；
- VLAN 或路由配置错误。

6. 链路层与上层可靠性

以太网帧有 FCS，能够发现部分传输错误，但普通以太网不会像 TCP 那样提供端到端确认和重传。

```
FCS：检查这一帧是否损坏
TCP：检查丢失、乱序并在端到端重传
```

因此，“链路层有校验”和“链路层提供可靠传输”不是同一件事。

6.1 CRC 能发现什么

FCS 使用 CRC 计算帧头和数据，用于发现位翻转等传输错误。接收网卡通常会在本地丢弃 FCS 错误的帧。

它不能：

- 证明发送方真的发出了业务数据；
- 补发丢失的帧；
- 保证到达顺序；
- 防止恶意伪造；
- 解决 IP 路由错误。

6.2 抓包为什么经常看不到 FCS

很多网卡在驱动或硬件层已经完成 FCS 校验，再把帧交给抓包工具；有些抓包接口不提供 FCS 字段。看不到 FCS 不代表以太网没有进行 CRC 校验。

6.3 以太网不只是一个速率

“以太网”覆盖多种布线、速率和双工模式：

```
10BASE-T
100BASE-TX
1000BASE-T
10GBASE-T
光纤以太网
```

上层 IP 不关心当前是双绞线还是光纤。链路层负责最大帧长、地址格式和访问控制，物理层负责电信号或光信号。

虚拟机、容器和隧道又会增加虚拟以太网接口，例如：

```
veth
bridge
tun/tap
```

抓包时看到的接口不一定对应一块真实物理网卡。

7. 一个以太网帧的具体视角

假设主机发送 IPv4 TCP 报文：

```
目的 MAC：路由器接口 MAC
源 MAC：主机网卡 MAC
EtherType：0x0800
数据：IPv4 数据报
FCS：链路校验
```

如果发送 ARP 请求：

```
目的 MAC：FF:FF:FF:FF:FF:FF
源 MAC：主机网卡 MAC
EtherType：0x0806
数据：28 字节 ARP 请求 + PAD
```

虽然两者外层都由以太网承载，但 EtherType 决定接收方把有效载荷交给 IPv4 还是 ARP。

7.1 交换机不读取 IP 目的地址

在普通二层转发中，交换机主要读取：

```
源 MAC
目的 MAC
VLAN
```

它通常不需要读取 IP 地址。IP 目的地址由路由器或三层交换机处理。

若交换机被配置成三层网关，它才会参与 IP 路由，此时也承担路由器角色。

8. 局域网性能为什么会被主机数量影响

在共享式以太网中，主机越多、发送越频繁，碰撞概率越高。碰撞后需要停止并退避，实际吞吐量降低。

交换机把大的共享碰撞域切成多个较小的碰撞域：

```
共享总线：所有主机争用同一条介质
交换网络：每个端口独立发送和接收
```

但主机数量仍然可能影响性能：

- 上行链路不够；
- 交换机背板或转发能力不足；
- 广播流量增加；
- ARP 请求增加；
- 大量未知单播泛洪；
- 无线接入点共享空口资源；
- 某些主机占用过高带宽。

因此“交换机消除碰撞”不代表“网络不会拥塞”。

8.1 全双工与半双工

模式	发送和接收	碰撞
半双工	共享介质，方向互斥	可能发生
全双工	收发独立	传统共享总线碰撞通常不发生

如果两端双工模式不匹配，可能出现严重丢包和性能下降。现代交换机通常自动协商，但故障设备或固定配置仍可能造成双工不匹配。

8.2 链路速率与吞吐量

链路速率是物理层理论比特率，不代表应用吞吐量。以太网帧还有：

- 前导码和帧间隙；
- 帧头；
- FCS；
- 协议首部；
- 上层确认和重传。

因此 1 Gbps 链路不可能让一个应用稳定得到完整的 1 Gbps 有效载荷。

8.3 观测接口与链路

Linux 常用：

```
ip link
ethtool eth0
ethtool -S eth0
```

可以观察：

- 链路是否 UP；
- 速率和双工；
- MTU；
- MAC 地址；
- 收发错误、丢包和队列统计。

应用超时不一定来自程序，可能从网卡统计中已经能看到物理层错误。

9. 从帧到网卡

9.1 帧不是抽象对象

操作系统把数据交给网卡驱动后，驱动会组织发送描述符，将帧通过 DMA 交给硬件。链路状态、队列、中断和校验都由驱动与网卡协作完成。

从应用视角，`send` 返回可能只表示数据进入内核；从链路视角，帧还要经过：

```
协议栈封装
-> 发送队列
-> 网卡 DMA
-> 物理编码
-> 链路传输
```

所以“应用写成功”不能直接证明帧已经在物理线路成功发送。

9.2 队列与丢包

当接口发送速率小于上层产生流量的速度时，发送队列可能满：

```
qdisc queue -> 满 -> 丢包
```

交换机端口拥塞也会丢帧。此时抓包可能看到发送端已经发出、接收端却没有收到，问题并不在应用协议。

可用：

```
ip -s link show eth0
tc -s qdisc show dev eth0
```

观察队列、丢包和错误计数。

9.3 VLAN 帧的额外长度

带 802.1Q 标签的以太网帧会在源 MAC 后增加 4 字节标签：

```
普通最大帧：1518 字节
单层 VLAN 最大帧：1522 字节
```

标签中包含 VLAN ID、优先级等信息。交换机根据端口模式插入、删除或保留标签，主机通常收到去掉标签后的帧。

9.4 交换机角色与路由器角色

普通二层交换机：

- 根据目的 MAC 转发；
- 学习源 MAC；
- 通常不降低 IP TTL；
- 不修改 IP 地址；
- 不连接两个不同 IP 子网作为三层网关。

路由器：

- 根据目的 IP 查路由；
- 降低 TTL；
- 生成新的链路层帧；
- 连接不同子网；
- 可能执行 NAT 和 ACL。

一台物理设备可以同时具有交换和路由功能，但分析问题时仍要明确当前处理的是二层还是三层。

9.5 抓包时如何判断问题层级

看到无法访问时，可以按帧逐项检查：

1. 帧是否真的从源接口发出；
2. 目的 MAC 是否是正确下一跳；
3. EtherType 是否正确；
4. FCS 错误是否出现在接收侧；

5. 交换机是否把帧泛洪或转发到了错误端口；
6. 目标是否发出 ARP 应答；
7. 目的 IP 是否保持不变；
8. TTL 是否按预期减少。

如果目的 MAC 写错，IP 路由表再正确也无法让帧到达下一跳；如果交换机未知单播大量泛洪，可能是 MAC 学习、端口隔离或环路问题。

9.6 广播不是可靠发现协议

ARP 和 DHCP 等协议依赖广播或组播发现邻居，但广播范围过大时：

- 所有端口都被无关帧占用；
- 无线空口效率下降；
- 广播风暴风险增加；
- ARP 欺骗影响范围扩大。

因此企业网络通常使用 VLAN、端口隔离、DHCP Snooping、动态 ARP 检测和广播抑制，而不是让一个巨大的二层网络无限扩展。

9.7 二层故障检查清单

```
接口是否 UP
速率与双工是否匹配
本地 MAC 与目的 MAC 是否正确
VLAN 是否一致
交换机是否学到 MAC
是否存在广播风暴或环路
MTU 是否足以承载当前报文
FCS、CRC、丢包计数是否增长
```

只有确认帧已经正确到达下一跳，才有必要继续分析上层 IP 路由和应用错误。

抓包查看二层字段：

```
sudo tcpdump -eni eth0 arp
sudo tcpdump -eni eth0 ether proto 0x0800
```

`-e` 会显示源和目的 MAC，适合检查“IP 路由正确但下一跳 MAC 错误”的二层问题。

10. 还缺一步：下一跳 MAC 从哪里来

主机已经知道下一跳 IP，也知道怎样封装帧，但仍需要下一跳的 MAC 地址。唯一确定的方法是在当前广播域内询问。

下一篇进入 ARP：一个 IP 地址怎样通过广播请求转换为 MAC，结果如何缓存，以及攻击者如何伪造应答。