Linux网络--网络层IP协议、地址与子网划分

- Linux网络--网络层IP协议、地址与子网划分
- 1. 从套接字走向网络层
  - 1.1 应用并不直接发送 IP 报文
  - 1.2 IP 的能力与边界
  - 1.3 主机、路由器和节点
- 2. IPv4 首部
  - 2.1 标准首部与字段
  - 2.2 报头和有效载荷如何分离
  - 2.3 TTL 与校验
- 3. IP 地址与网段
  - 3.1 网络号与主机号
  - 3.2 子网掩码
  - 3.3 分类地址与 CIDR
- 4. 子网计算
  - 4.1 /24 示例
  - 4.2 /28 示例
  - 4.3 特殊地址
  - 4.4 同一子网到底怎样判断
  - 4.5 子网划分和路由聚合不是一回事
  - 4.6 主机地址从哪里来
  - 4.7 掩码合法性
  - 4.8 主机、网关和路由器地址
- 5. 一个数据报的完整封装过程
  - 5.1 应用写入
  - 5.2 添加 TCP 首部
  - 5.3 添加 IP 首部
  - 5.4 添加链路层首部
  - 5.5 接收方如何反向拆解
  - 5.6 为什么不直接发送应用数据
- 6. IP 地址为什么仍然不够
- 7. IPv4 与 IPv6
  - 7.1 地址空间差异
  - 7.2 为什么今天仍然经常看到 IPv4
  - 7.3 IP 地址不等于主机身份
- 8. 观察 IP 报文

    - 8.1 报文视角
    - 8.2 源地址和目的地址的意义
    - 8.3 常见观测工具
    - 8.4 抓包位置改变结论
    - 8.5 抓包时的首部分层
- 9. 本篇小结

Linux网络--网络层IP协议、地址与子网划分

> ⓘ **系列导航**
>
> 本篇：IP 报文、地址与子网划分
> 下一篇：Linux网络--网络层私有IP、NAT与公网访问

IP 是网络层最重要的协议。它不承诺报文一定到达，而是负责在复杂网络中找到一条可行路径，把数据从源主机尽可能送往目的主机。可靠性、排序和重传由上层协议处理，其中最常见的组合是 TCP/IP。

本篇先解决三个基础问题：IP 在协议栈中负责什么、IPv4 首部如何描述报文、IP 地址如何通过子网掩码区分网络和主机。理解这些内容后，后续的路由、NAT、分片和 ARP 才有了共同语言。

1. 从套接字走向网络层

1.1 应用并不直接发送 IP 报文

应用调用 `send/write` 后，数据先进入内核协议栈。TCP 或 UDP 为数据添加传输层首部，IP 再添加网络层首部，最后链路层将其封装成帧。

Linux 中的对象关系可以简化为：

```
struct socket
    -> struct sock
        -> struct inet_sock
            -> struct tcp_sock / struct udp_sock
```

`struct socket` 提供通用套接字接口，`struct sock` 保存协议公共状态，`inet_sock` 和 TCP/UDP 专用结构继续扩展字段。公共结构通常放在派生结构开头，因此通用协议栈可以把具体协议对象当成基础对象处理。

同时强调：不同操作系统的内部实现可以不同，但 TCP/IP 的报文格式和分层规则必须一致，否则 Linux、Windows 和网络设备之间无法互通。

1.2 IP 的能力与边界

IP 提供的是“跨网络交付能力”：

- 根据目的 IP 选择路径；
- 允许经过多个路由器；
- 对上层屏蔽不同链路技术的差异；
- 在发生拥塞或链路错误时允许丢弃报文。

IP 不负责保证送达，也不负责修正乱序。TCPUDP 图层的可靠策略建立在 IP 的尽力而为服务之上。

```
IP：把数据尽可能送到目标主机
TCP：在不可靠通道上建立可靠字节流
```

1.3 主机、路由器和节点

概念	职责
主机	拥有 IP 地址，发送和接收报文，并根据路由表选择出口
路由器	拥有多个接口，在不同网络之间转发报文
节点	主机和路由器的统称

主机虽然通常不替其他网络转发报文，但它仍然有路由表。访问本机回环、本地子网或远端网络时，主机必须决定报文走哪个接口。

2. IPv4 首部

2.1 标准首部与字段

IPv4 标准首部为 20 字节。若包含选项，最大可到 60 字节。

字段	长度	作用
版本	4 位	IPv4 填 4
首部长度	4 位	以 4 字节为单位，标准值 5，即 20 字节
服务类型 TOS	8 位	课程按旧式优先级、时延、吞吐和可靠性解释；现代网络通常使用 DSCP
总长度	16 位	首部与有效载荷的总长度，最大 65535 字节
标识	16 位	同一原始数据报的各个分片共享标识
标志	3 位	保留位、DF、MF
片偏移	13 位	当前分片在原始有效载荷中的位置，以 8 字节为单位
TTL	8 位	剩余可经过的路由跳数
协议	8 位	指出有效载荷交给哪个上层协议
首部校验和	16 位	只校验 IP 首部
源 IP	32 位	发送方地址
目的 IP	32 位	最终目标地址
选项	0 至 40 字节	可选控制信息
数据	可变	TCP 段、UDP 数据报或 ICMP 报文等

常见协议号：

- `1`：ICMP；
- `6`：TCP；
- `17`：UDP。

2.2 报头和有效载荷如何分离

接收方先读取 4 位首部长度：

```
IP 首部字节数 = 首部长度字段值 * 4
```

再读取 16 位总长度：

```
有效载荷长度 = 总长度 - 首部长度
```

得到有效载荷后，根据协议字段向上分用。例如协议号为 6，就交给 TCP；协议号为 17，就交给 UDP。

2.3 TTL 与校验

报文每经过一个三层路由器，TTL 通常减 1。TTL 为 0 时，路由器丢弃报文并向发送方反馈超时。TTL 既能限制环路中的报文寿命，也为 `traceroute` 提供了探测路径的基础。

IP 首部校验和采用 16 位反码求和算法，不是 CRC。CRC 常用于以太网帧的 FCS。IP 校验只覆盖首部，TCP、UDP 或 ICMP 对有效载荷有自己的校验机制。

3. IP 地址与网段

3.1 网络号与主机号

IPv4 地址为 32 位，用来同时表达两个层次：

```
IP 地址 = 网络号 + 主机号
```

网络号让路由设备先定位目标网络，淘汰大量无关网段；主机号在目标网络内部定位具体接口。

可以用学校与学号作类比：

- 学院号相当于网络号，先确定目标区域；
- 个人编号相当于主机号，再定位具体对象。

路由查找之所以高效，是因为设备不需要遍历互联网上的每一台主机，而可以先按网络前缀做批量淘汰。

3.2 子网掩码

子网掩码也是 32 位，左侧是连续的 1，右侧是连续的 0。

```
IP地址 AND 子网掩码 = 网络地址
```

例如：

```
IP:   192.168.128.10
Mask：255.255.255.0
网段：192.168.128.0/24
```

`192.168.128.10/24` 和 `192.168.128.11/24` 的网络号相同，主机号不同，因此可以处在同一个子网。

路由器连接两个不同网段时，两个接口必须配置不同的网络标识：

```
接口 1：192.168.128.1/24
接口 2：192.168.144.1/24
```

3.3 分类地址与 CIDR

早期把 IPv4 地址分为 A、B、C、D、E 五类。分类法的问题在于地址块粒度过粗：组织申请一个 A 类或 B 类网络后，往往只使用其中很小一部分，造成大量浪费。

CIDR 使用任意长度的网络前缀，不再让 A/B/C 类决定网络号边界。`/24`、`/20`、`/28` 都可以根据实际需求划分地址块。

分类法是互联网早期历史，CIDR 是现代路由和地址规划的基础。二者可以在同一系统中同时出现，但现代配置主要使用前缀长度表示。

4. 子网计算

4.1 `/24` 示例

```
IP：140.252.20.68
Mask：255.255.255.0
网络号：140.252.20.0
范围：140.252.20.0 - 140.252.20.255
```

该子网共有 `2^8 = 256` 个地址：

- 主机位全 0 的 `.0` 是网络地址；
- 主机位全 1 的 `.255` 是直接广播地址；
- 常规可用主机地址为 `256 - 2 = 254` 个。

4.2 `/28` 示例

```
IP：140.252.20.68
Mask：255.255.255.240
网络号：140.252.20.64
范围：140.252.20.64 - 140.252.20.79
```

计算过程：

```
240 = 1111 0000
68  = 0100 0100
68 AND 240 = 0100 0000 = 64
```

`/28` 留下 4 位主机号，因此每个子网有 `2^4 = 16` 个地址，可用地址为 `16 - 2 = 14` 个。

4.3 特殊地址

地址形式	含义
主机位全 0	网络地址，表示整个子网
主机位全 1	该子网的直接广播地址
`127.0.0.0/8`	本机回环地址范围，常用 `127.0.0.1`

对 `127.0.0.1` 的访问不会进入真实链路，而是通过回环接口在主机协议栈内部完成。

4.4 同一子网到底怎样判断

判断两台主机是否处在同一子网，不能用“IP 前三个数字看起来一样”来判断，而要用各自的掩码计算网络地址。

```
主机 A：192.168.10.20/24
主机 B：192.168.10.230/24

网络 A：192.168.10.20  AND 255.255.255.0 = 192.168.10.0
网络 B：192.168.10.230 AND 255.255.255.0 = 192.168.10.0
```

因为网络地址相同，A 认为 B 与自己在同一链路，可以直接通过 ARP 查找 B 的 MAC。

再比较：

```
主机 A：192.168.10.20/24
主机 C：192.168.11.20/24
```

计算后分别得到 `192.168.10.0` 和 `192.168.11.0`，网络地址不同。A 会把报文交给默认网关，由路由器在不同子网之间转发。

如果掩码不一致，即使地址非常接近，双方也可能对“本地网络”产生不同判断：

```
主机 A：192.168.10.20/24
主机 B：192.168.10.230/25
```

A 认为 B 在同一 `/24` 网络；B 认为 A 在另一个 `/25` 网络并尝试交给网关。网络规划必须保证同一广播域内掩码一致，否则会出现“有时能通、有时不通”的奇怪故障。

4.5 子网划分和路由聚合不是一回事

子网划分把一个较大的地址块切成多个较小的网络：

```
10.1.0.0/16
    -> 10.1.1.0/24
    -> 10.1.2.0/24
    -> 10.1.3.0/24
```

路由聚合则把多个连续网络汇总成一条路由：

```
10.1.1.0/24
10.1.2.0/24
10.1.3.0/24
    -> 10.1.0.0/16
```

子网划分关注“地址块内部如何组织”，路由聚合关注“减少路由表中重复的转发条目”。CIDR 同时支持这两种操作。

4.6 主机地址从哪里来

网络号定义了主机可以使用的地址范围，但主机如何得到具体地址，常见方式有：

1. 手工静态配置；
2. DHCP 自动分配；
3. IPv6 的 SLAAC 或 DHCPv6；
4. 容器和虚拟化平台由控制面分配。

家用路由器通常同时承担：

- 默认网关；
- DHCP 服务器；
- DNS 代理；
- NAT/NAPT 设备。

主机通过 DHCP 得到的并不只有 IP 地址，还可能包括：

```
子网掩码
默认网关
DNS 服务器
地址租约时间
其他网络参数
```

DHCP 常见交互可以概括为 discover、offer、request、ack。租约到期或主机重新接入时，地址可能变化，这也是后续 ARP 缓存不能永久有效的原因之一。

4.7 掩码合法性

现代 IPv4 无类别前缀的掩码必须由连续的 1 和连续的 0 组成：

```
合法：255.255.240.0   -> 11111111 11111111 11110000 00000000
非法：255.252.240.0   -> 1 与 0 不连续
```

前缀长度和前 1 的个数必须一致：

前缀	掩码
/16	255.255.0.0
/20	255.255.240.0
/24	255.255.255.0
/28	255.255.255.240

示例城市三级模型中的西安 `5.1.16.0/20` 就应使用 `255.255.240.0`。如果出现 `255.252.240.0`，说明不是合法的连续前缀掩码。

4.8 主机、网关和路由器地址

在一个 `/24` 网络中，通常会约定一个地址作为网关：

```
网段：192.168.1.0/24
可用范围：192.168.1.1 - 192.168.1.254
常见网关：192.168.1.1
主机示例：192.168.1.20
```

网关地址本身也是主机地址，只是它配置在路由器连接该网段的接口上。路由器的另一接口可能属于完全不同的网络。

例如：

```
LAN 接口：192.168.1.1/24
WAN 接口：10.1.1.2/24
```

路由器正是通过“两个接口属于两个网络”完成跨网连接。

5. 一个数据报的完整封装过程

假设应用运行在主机 A，向主机 B 的某个 TCP 服务发送请求。把前面的首部和地址知识串联起来，可以得到完整过程。

5.1 应用写入

应用产生业务数据：

```
GET /index.html HTTP/1.1
Host: example.com
```

应用调用 `send` 后，数据进入内核 TCP 发送缓冲区。TCP 根据 MSS、窗口和拥塞状态选择本次发送的数据范围。

5.2 添加 TCP 首部

TCP 形成段：

```
源端口
目的端口
序号
确认号
控制标志
窗口
校验和
数据
```

传输层根据目的端口把数据交给目标进程；网络层此时只把整段 TCP 数据当成有效载荷。

5.3 添加 IP 首部

IP 层填写：

```
版本 = 4
首部长度 = 5
总长度 = IP 首部 + TCP 段
协议 = 6
源 IP = 主机 A
目的 IP = 主机 B
TTL = 初始值
```

如果 TCP 段加上 IP 首部超过链路 MTU，IPv4 层可能继续分片，这一过程在分片专篇中解释。

5.4 添加链路层首部

主机查路由表，确认下一跳。若目的主机就是同网段目标，下一跳是主机 B；若不在同网段，下一跳是默认网关。

随后通过 ARP 获得下一跳 MAC，形成：

```
目的 MAC
源 MAC
EtherType=0x0800
IP 数据报
FCS
```

从这里开始，网络层数据真正进入网卡和物理链路。

5.5 接收方如何反向拆解

接收方从下往上：

1. 链路层检查目的 MAC 和 FCS；
2. 根据 EtherType 识别 IPv4；
3. IP 用首部长度确定 IP 头长度；
4. IP 用总长度确定有效载荷；
5. 根据协议字段交给 TCP；
6. TCP 根据目的端口找到 socket；
7. 数据进入接收缓冲区；
8. 应用调用 `recv/read` 读取。

这条链路上，IP 只负责把整段数据送到目标主机，具体交给哪个进程由传输层端口完成。

5.6 为什么不直接发送应用数据

如果没有分层：

- 不同应用要自己处理路由；
- 不同链路技术要重新定义地址；
- 丢包和重传无法复用；
- 不同操作系统之间无法统一定义通信格式；
- 一个应用协议改变会影响底层网络。

分层让每一层只解决有限问题。IP 所在层不关心 HTTP 或 SSH 的语义，只负责主机到主机的跨网络交付。

6. IP 地址为什么仍然不够

IPv4 只有 `2^32` 个地址，还要扣除特殊地址，并为路由器、服务器和多网卡设备分配地址。CIDR 提高了利用率，但没有增加地址总量。

常见解决方式包括：

1. 动态地址分配；
2. 私有地址与 NAT；
3. IPv6。

私有地址允许不同隔离网络重复使用。于是出现了下一篇的核心问题：目标主机只携带目的 IP，当源地址是不可在公网路由的私有地址时，报文怎样进入互联网，返回报文又怎样找到原始主机？

7. IPv4 与 IPv6

7.1 地址空间差异

IPv4 地址为 32 位，IPv6 地址为 128 位。二者不是简单扩大字段的同一协议：

- 首部布局不同；
- 地址表示方法不同；
- 分片方式不同；
- IPv6 使用 ICMPv6 完成邻居发现等基础功能；
- IPv4 和 IPv6 可以在双栈主机上同时运行，但应用连接必须明确使用哪个地址族。

“IPv4 与 IPv6 不兼容”不表示二者不能共存。现代操作系统通常支持双协议栈，通过 DNS 的 A 和 AAAA 记录分别获得两类地址。

7.2 为什么今天仍然经常看到 IPv4

IPv4 具有庞大的既有设备和运维体系。NAT、私有地址、CGNAT 延长了 IPv4 的使用寿命，因此新网络往往同时部署 IPv4 和 IPv6，而不是某一天整体关闭 IPv4。

7.3 IP 地址不等于主机身份

同一个主机可以拥有多个接口，每个接口有多个地址；同一个公网出口地址也可以被大量 NAT 用户共享。因此，“一个 IP 对应一台固定设备”只是在简单模型中近似成立。

8. 观察 IP 报文

8.1 报文视角

用 `tcpdump` 或 Wireshark 抓包时，需要区分：

```
链路层帧头
IP 首部
TCP/UDP/ICMP 载荷
应用数据
```

IP 首部中的总长度能够帮助解析器确定当前 IP 数据报到哪里结束；协议号决定有效载荷解析方式；TTL 能反映报文在当前节点还剩多少跳；标识、标志和偏移用于识别分片。

8.2 源地址和目的地址的意义

- 源 IP 通常用于接收回包；
- 目的 IP 参与路由；
- NAT 可能在网络边界改写地址；
- 代理可能创建一条全新的应用层连接，而不只是改写一个字段。

因此排查问题时，不能只看应用日志中的“对端 IP”，还要确认它看到的是哪个网络边界之后的地址。

8.3 常见观测工具

Linux：

```
ip addr
ip route
ip neigh
ss -lntup
```

抓取指定接口的 IP 报文：

```
sudo tcpdump -ni eth0 'ip'
```

只抓 ICMP：

```
sudo tcpdump -ni eth0 icmp
```

只抓某个主机：

```
sudo tcpdump -ni eth0 host 192.168.1.20
```

`tcpdump` 的过滤表达式发生在抓包层，仍需要在输出中观察源地址、目的地址、协议、TTL、长度和分片字段。

8.4 抓包位置改变结论

同一条连接在客户端、网关和服务器上看到的五元组可能不同：

```
客户端：src=192.168.1.20
家用边界：src=10.1.1.2
运营商边界：src=122.77.241.4
服务器：src=122.77.241.4
```

如果在不同设备上取证，必须记录抓包点，否则会把 NAT 当成分组地址“被篡改”。

8.5 抓包时的首部分层

Wireshark 中常见折叠层次：

```
Frame
Ethernet II
Internet Protocol Version 4
Transmission Control Protocol
Hypertext Transfer Protocol
```

IP 层的字段回答：

- 源、目的是谁；
- 用哪种上层协议；
- 报文总长；
- TTL 还剩多少；
- 是否分片；
- 首部是否损坏。

TCP 层字段再回答端口、序号、确认和窗口；应用层才回答 HTTP 请求内容。

9. 本篇小结

```
IP 提供跨网络转发能力
IPv4 首部描述长度、协议、TTL 和地址
子网掩码把 IP 分成网络号与主机号
CIDR 用任意前缀提高地址利用率
同网段判断必须使用掩码计算网络地址
DHCP 为主机提供地址和网关等配置
地址复用还需要私有地址和 NAT
```

下一篇从家庭网络的 LAN/WAN 接口出发，解释私有 IP 如何逐层转换成公网 IP，以及 NAPT 为什么必须同时记录端口。